

Souběžné učení v koevolučních algoritmech

Michal Wiglasz (xwigla00@stud.fit.vutbr.cz)


Příspěvek 27

Cíl práce


Cílem této práce je navrhnout a experimentálně vyhodnotit koevoluci CGP a přímo kódovaných prediktorů fitness, jejichž velikosti se adaptuje na složitost řešeného problému v průběhu evoluce pomocí souběžného učení. Tímto se odstraní potřeba časově náročného experimentování s cílem nalézt co nejvýhodnější velikost prediktoru pro řešený problém.

Evoluční návrh obrazových filtrů

Většina obrazových filtrů pracuje s lokálním okolím pixelů, například devíti-okolí. Jeho vstupem jsou hodnoty všech pixelů v okolí a výstupem nová hodnota pixelu v jeho středu. Filtre se postupně aplikuje na celý obrázek.

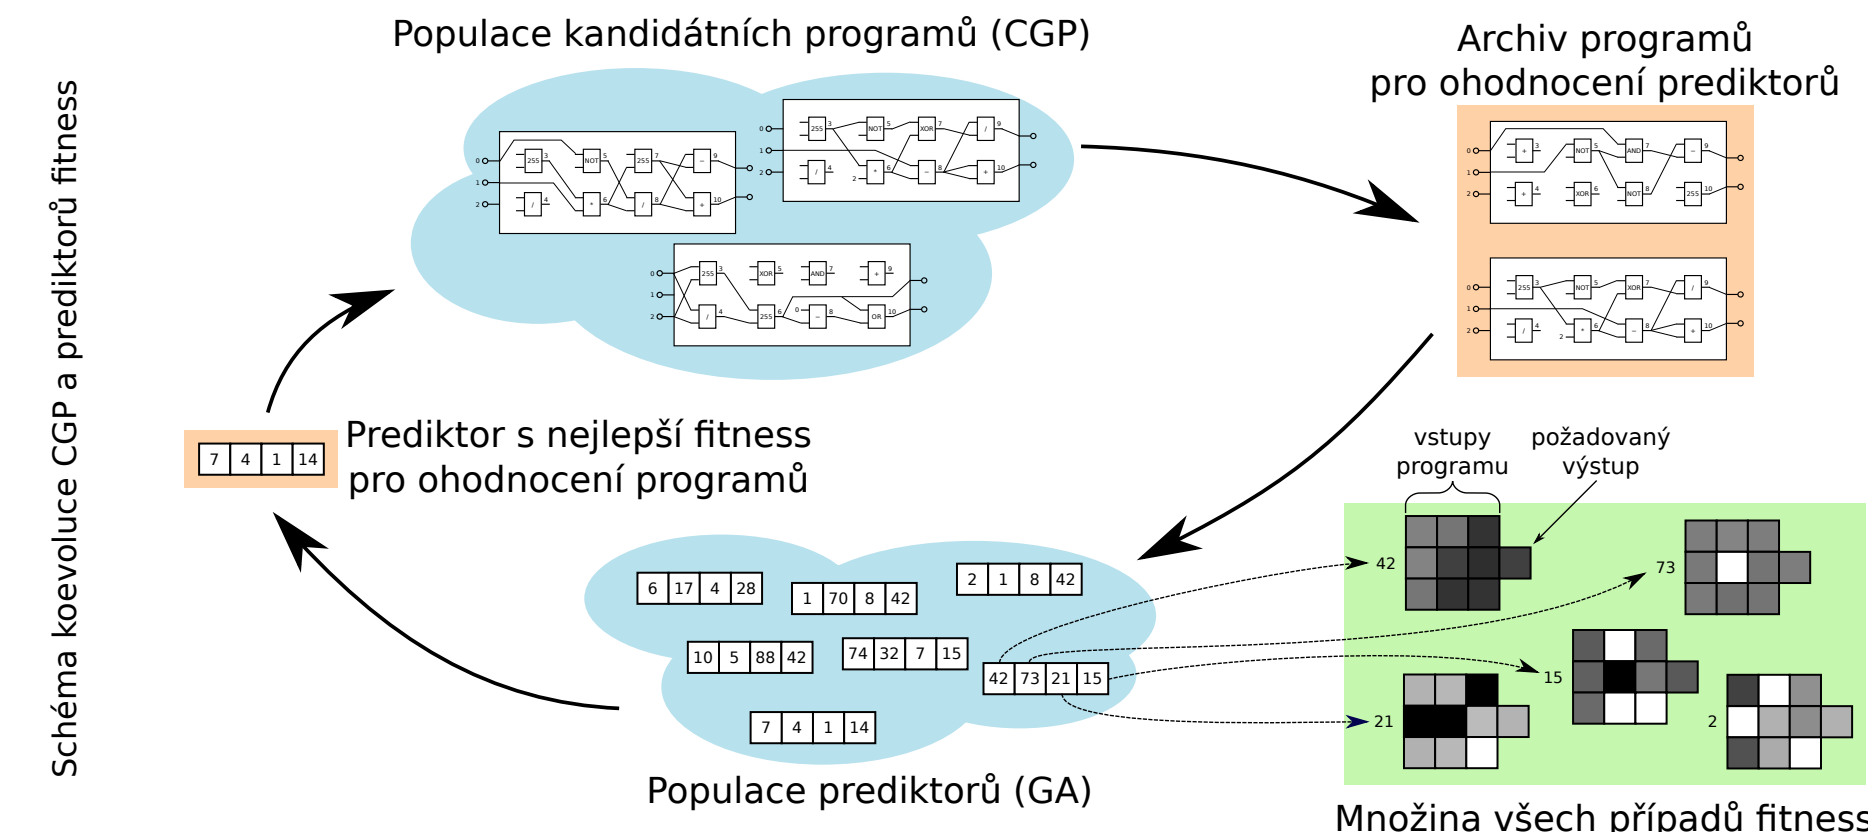


Obrazové filtry lze automatizovaně navrhovat pomocí kartézského genetického programování (CGP). Filtre je reprezentován jako mřížka funkčních bloků. Jejich funkce a vzájemné propojení jsou nalezeny evolučním algoritmem. Trénovací data tvoří dva obrázky, jeden slouží jako vstup filtru a druhý jako referenční výstup. Pro porovnání a určení kvality filtru se používá například funkce Peak Signal to Noise Ratio (PSNR).



Koevoluce s prediktory fitness

Evoluční návrh obrazových filtrů lze urychlit zavedením druhé populace tzv. prediktorů fitness, které slouží pro přibližné určení kvality filtru. Predikovaná fitness se počítá se počítá pomocí podmnožiny všech pixelů trénovacího obrázku, kterou určuje prediktor. Prediktory se vyvíjejí paralelně s filtry pomocí genetického algoritmu.

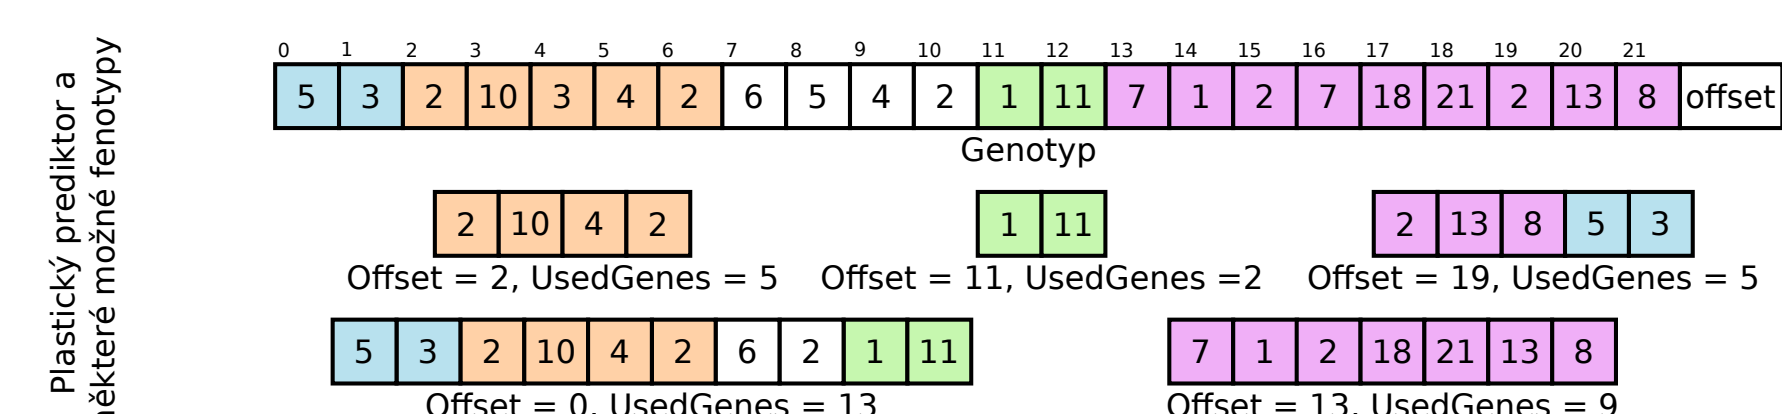


Adaptivní prediktory fitness

Jednou z nevýhod koevoluce je výběr vhodné velikosti prediktorů. Pokud jsou příliš malé, nejsou nalezené filtry tak kvalitní, pokud jsou příliš velké, je evoluce zbytečně pomalá. Navíc se ukázalo, že záleží i na řešené úloze. Například velikost prediktorů vhodná pro úlohu symbolické regrese není dostatečná pro nalezení kvalitních obrazových filtrů.

Při evoluci se souběžným učením mají jedinci tzv. plastický fenotyp, který nezáleží jen na genotypu, ale také na prostředí, a ze stejného genotypu tak může vzniknout několik fenotypů. Toho se dá využít k adaptaci velikosti prediktoru na složitost úlohy tím, že se změní počet genů, které se použijí při tvorbě fenotypu. Tento počet se upravuje podle změn skutečné fitness nejlepšího filtru takto:

- 1) Pokud je nepřesnost predikce příliš vysoká, prediktory se prodlouží.
- 2) Pokud se fitness nemění, evoluce pravděpodobně uvázla v lokálním optimu a prediktory se zkrátí, což může pomoci toto optima opustit.
- 3) Pokud fitness klesá, evoluce pravděpodobně opouští lokální optimum a mírné zkrácení prediktoru může pomoci postup urychlit.
- 4) Pokud fitness roste, prediktory se prodlouží a tím se zpřesní predikce.




Implementace navrženého algoritmu

Program je implementován v jazyce C a paralelizován pomocí direktiv ze standardu OpenMP. Výpočet výstupů kandidátních filtrů, což je časově nejnáročnější část výpočtu, je implementován také pomocí vektorových instrukcí SSE2 a AVX2. Pomocí nich lze zpracovávat 16 (nebo 32) pixelů najednou. Zrychlení je při použití SSE2 přibližně 10násobné, při použití AVX2 zhruba 16násobné (standardní CGP bez koevoluce).

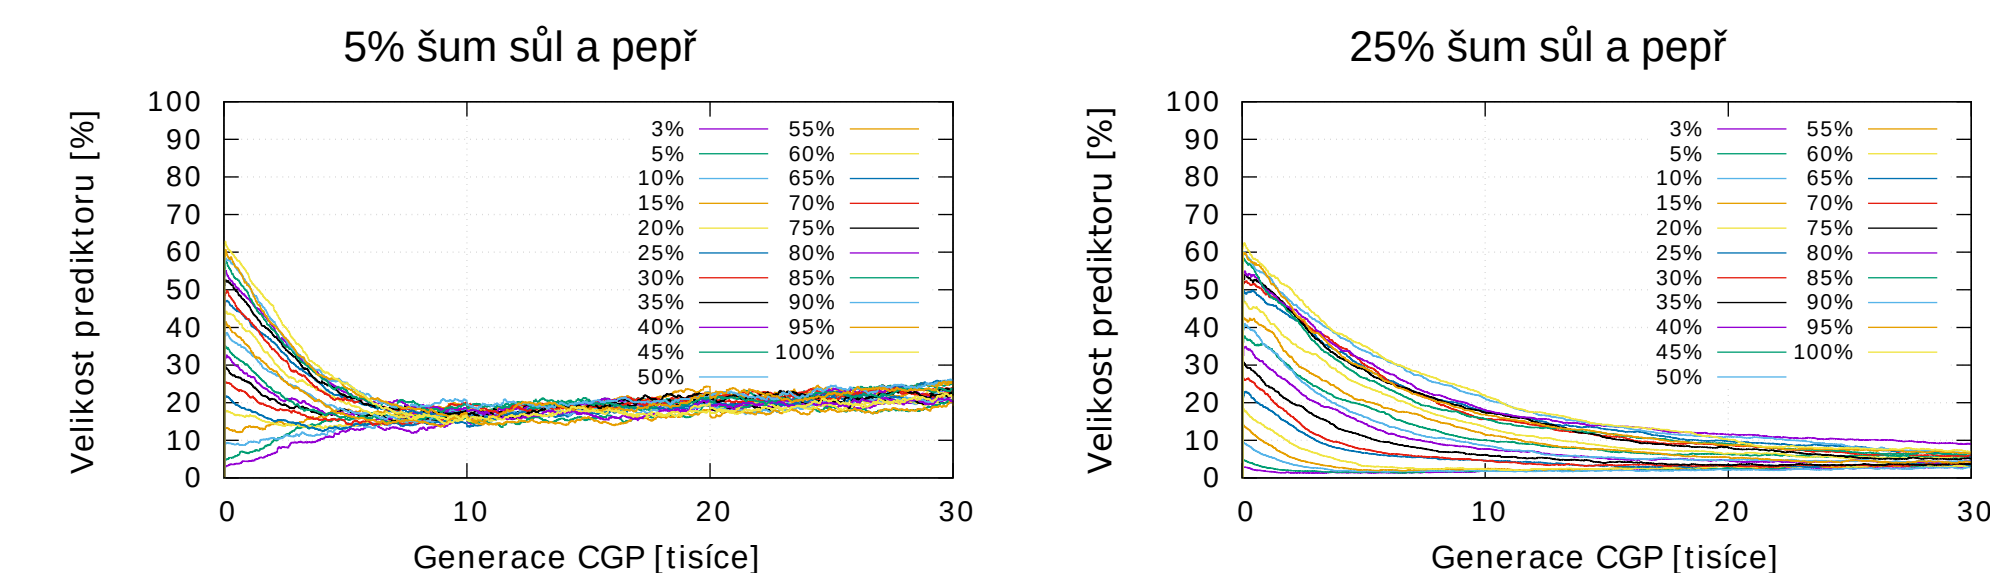
Pro sériové zpracování je výhodnější ukládat vstupní data jako pole devíti-okolí, Naopak, pro vektorové zpracování je výhodnější mít strukturu deseti polí pro každou pozici v devítiokolí a požadovaný výstup pro daný pixel.

Také je vhodné před výpočtem predikované fitness data pro pixely určené prediktorem zkopírovat do pomocné struktury, aby byly v paměti za sebou.



Schopnost adaptace velikosti prediktoru


Ukázalo se, že velikost prediktoru konverguje ke stejné hodnotě bez ohledu na počáteční nastavení velikosti. Je ale výhodnější začít s kratšími prediktory, protože výpočet predikované fitness je pak rychlejší.



Vývoj velikosti prediktoru při různé počáteční velikosti

Srovnání s CGP a koevolucí s pevnými prediktory

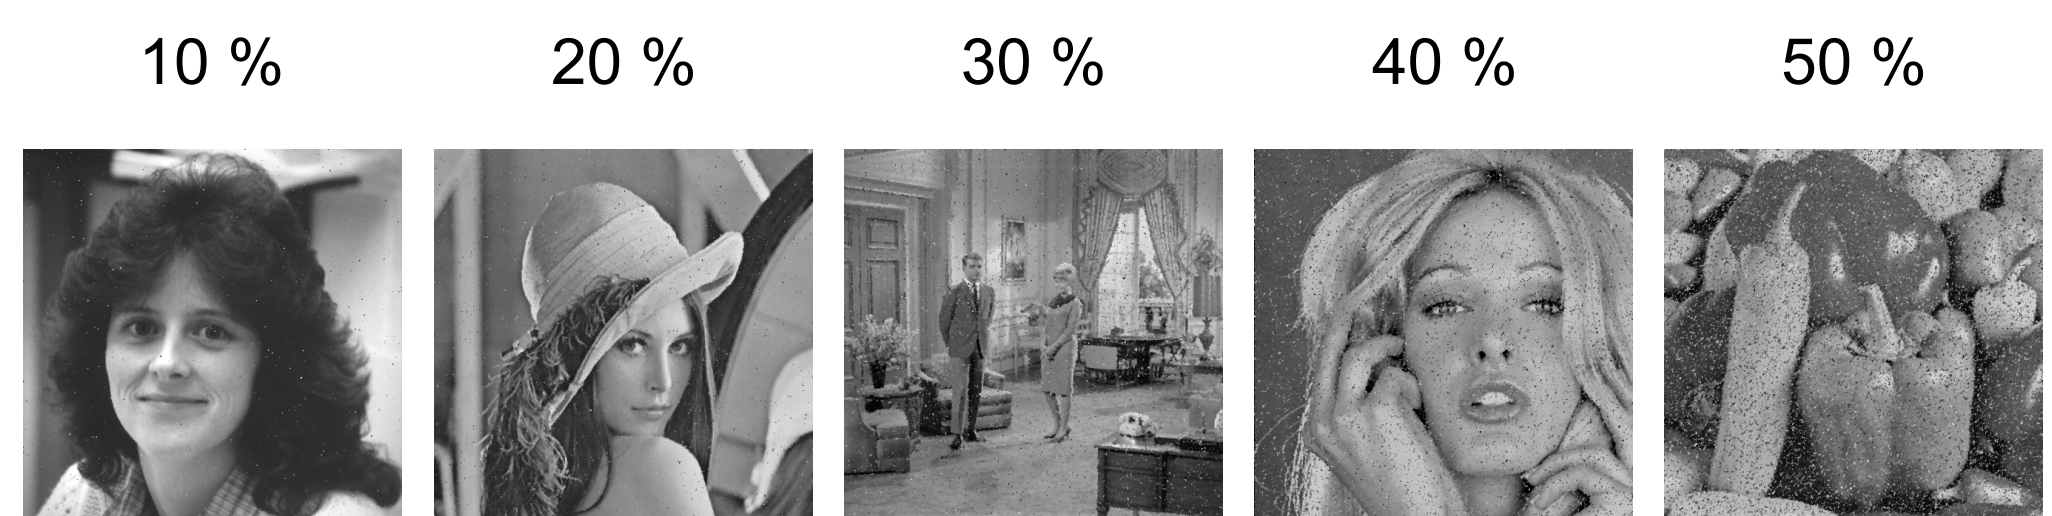
Z provedených experimentů vyplývá, že kvalita získaných filtrů se příliš neliší od výsledků koevoluce s prediktory pevné délky a také od výsledků standardního CGP. Oproti standardnímu CGP bylo dosaženo v průměru 8,39násobného zrychlení (součet času pro všechna vlákna). Také odpadá nutnost časově náročného experimentálního hledání nejvýhodnější velikosti prediktorů pro danou úlohu.



Srovnání CGP, koevoluce CGP s pevnými prediktory fitness a koevoluce s adaptivními prediktory (A) pro 10% impulzní šum

Ukázka nalezených filtrů

Obrázky poškozené impulzním šumem



Výstup nejlepšího nalezeného filtru (1 krok filtrace)